

TECHNICAL REPORT
Prediksi Kategori Pendapatan Individu
Studi Kasus: Census Income (KDD) Dataset
Metrik Evaluasi Utama: F1-Macro


Nahdah Runa Musyaffa
103012530054

1. Introduction

Proyek ini bertujuan untuk membangun model machine learning yang dapat memprediksi kategori pendapatan individu berdasarkan karakteristik demografis, pendidikan, pekerjaan, dan kondisi finansial. Permasalahan ini merupakan supervised learning dengan pendekatan binary classification, dengan target income yang terdiri dari dua kelas, yaitu $\leq 50K$ dan $>50K$, sehingga permasalahan diformulasikan sebagai binary classification.

Proses pengerjaan meliputi data cleaning, exploratory data analysis (EDA), preprocessing, feature engineering, eksperimen beberapa model yaitu Logistic Regression, Random Forest, dan CatBoost, evaluasi model, dan final prediction. Ketiga model menggunakan F1-Macro sebagai metrik utama.

2. Project Flow



3. Data Understanding dan Exploratory Data Analysis

3.1 Problem dan Dataset


```
Train shape: (39073, 15)
Test shape: (9769, 15)
Submission shape: (9769, 2)
```

Gambar 1. Informasi Dataset

- | | |
|---------------------|---------------------------------|
| a. Dataset | = Census Income (Adult) Dataset |
| b. Target | = income |
| c. Dataset Training | = train.csv |
| d. Final Prediction | = test.csv |
| e. Template Output | = sample_submission.csv |

Dataset training digunakan untuk proses eksplorasi, preprocessing, feature engineering, pelatihan, dan validasi model, sedangkan dataset testing digunakan secara khusus untuk menghasilkan prediksi akhir dan tidak dilibatkan dalam proses eksplorasi maupun pengembangan model.

3.2 Distribusi Target




Gambar 2. Distribusi kelas target (income)

	Train (%)	Validation (%)
income		
<=50K	76.06	76.06
>50K	23.94	23.94

Gambar 3. Distribusi dalam Presentase


Interpretasi : Berdasarkan Gambar 2, distribusi target terdiri dari 76,06% kategori <=50K dan 23,94% kategori >50K. Setelah dilakukan stratified splitting, proporsi kedua kelas pada data training dan validation tetap sesuai dengan distribusi awal.

3.3 Distribusi Fitur Numerik terhadap Income




Gambar 4. Distribusi usia berdasarkan kategori income

Interpretasi : Kelompok income >50K memiliki median usia yang lebih tinggi dibandingkan kelompok <=50K, yaitu sekitar 43 tahun dan 35 tahun. Hal ini menunjukkan adanya perbedaan distribusi usia antara kedua kategori income, sehingga *age* berpotensi memberikan informasi dalam prediksi income. .



Gambar 5. Distribusi Capital gain berdasarkan kategori income


Interpretasi : Distribusi capital-gain pada kedua kategori income sangat right-skewed, dengan mayoritas observasi berada di sekitar nol. Kelompok >50K memiliki beberapa nilai capital-gain yang tinggi, termasuk satu observasi ekstrem sekitar 100.000. Kondisi ini perlu diperhatikan pada tahap preprocessing karena nilai ekstrem dapat memengaruhi distribusi fitur.




Gambar 6. Distribusi jam kerja per minggu berdasarkan kategori income

Interpretasi: Kelompok income >50K memiliki sebaran jam kerja per minggu yang lebih luas dibandingkan kelompok <=50K. Selain itu, median jam kerja kelompok >50K lebih tinggi dibandingkan kelompok <=50K, yaitu sekitar 45 jam per minggu dibandingkan sekitar 37 jam per minggu. Hal ini menunjukkan adanya perbedaan distribusi *hours-per-week* antara kedua kategori income yang berpotensi memberikan informasi dalam prediksi.

3.4 Distribusi Fitur Kategorikal terhadap Income




Gambar 7. Jumlah baris/data pada fitur kategorikal



Gambar 8. Distribusi pendapatan berdasarkan pendidikan

Interpretasi : Berdasarkan distribusi tersebut, kelompok dengan tingkat pendidikan *Prof-school*, *Masters*, dan *Doctorate* memiliki proporsi pendapatan >50K yang lebih tinggi dibandingkan dengan tingkat pendidikan lainnya, meskipun jumlah observasi pada kategori tersebut lebih sedikit dibandingkan kategori seperti *HS-grad* dan *Bachelors*. Oleh karena itu, pola pada kategori dengan jumlah data yang lebih kecil perlu diinterpretasikan secara lebih hati-hati.




Gambar 9. Distribusi pendapatan berdasarkan pekerjaan

Interpretasi : Distribusi tersebut menunjukkan bahwa *Exec-managerial* dan *Prof-specialty* memiliki proporsi pendapatan >50K yang paling tinggi dibandingkan kelompok *occupation* lainnya. Sebaliknya, *Priv-house-serv* didominasi oleh individu dengan pendapatan ≤50K.

4. Preprocessing dan Feature Engineering

Pada tahap ini preprocessing dilakukan menggunakan satu pipeline yang sama untuk data training, validation, dan testing. Namun, aturan preprocessing dipelajari dari data training saja, kemudian diterapkan ke validation dan testing. Hal ini dilakukan agar informasi dari data validation dan testing tidak ikut digunakan saat model belajar.



Gambar 10. Tahap Preprocessing & Feature Engineering

Fitur numerik yang memiliki nilai kosong diisi menggunakan nilai median. Setelah itu, fitur numerik dilakukan standardisasi menggunakan StandardScaler agar setiap fitur memiliki skala yang lebih seragam. Sementara itu, fitur kategorikal yang memiliki nilai kosong diisi dengan kategori yang paling sering muncul, kemudian diubah menjadi bentuk numerik menggunakan One-Hot Encoding.

Feature Engineering pada *case* ini dilakukan dengan menambahkan dua fitur baru dari capital-gain dan capital-loss yang memiliki distribusi sangat skewed. Oleh karena itu, kedua fitur tersebut ditransformasi menggunakan fungsi logaritmik $\log_{1p}$. Transformasi ini dilakukan untuk mengurangi pengaruh nilai yang sangat besar sehingga distribusi fitur menjadi lebih terkendali.




	Experiment	F1-Macro
0	CatBoost - Original Features	0.810305
1	CatBoost - Feature Engineering	0.809794

Gambar 11. Perbandingan Model CatBoost pada kondisi features yang berbeda

Gambar 11 merupakan hasil perbandingan F1-Macro pada model yang mengalami feature engineering dan tidak. Berdasarkan hasil tersebut menunjukkan bahwa adanya feature engineering justru membuat performa menurun. Oleh karena itu, model akhir tetap menggunakan fitur original untuk menjaga kesederhanaan pipeline tanpa mengorbankan performa.

5. Eksperimen dan Evaluasi Model




	Model	F1-Macro
0	CatBoost	0.810305
1	Random Forest	0.789441
2	Logistic Regression	0.782437

Gambar 12. Perbandingan Model

Berdasarkan baseline comparison, CatBoost menghasilkan nilai F1-Macro tertinggi sebesar 0.8103, diikuti oleh Random Forest sebesar 0.7894 dan Logistic Regression sebesar 0.7824. Hasil ini menunjukkan bahwa CatBoost memberikan performa terbaik pada eksperimen baseline. Oleh karena itu, CatBoost dipilih sebagai model final untuk menghasilkan prediksi akhir pada data testing.

6. Prediksi dan Kesimpulan

6.1 Alur Prediksi Akhir



Gambar 13. Alur pembuatan prediksi

Model CatBoost dilatih ulang menggunakan seluruh data training, kemudian digunakan untuk menghasilkan prediksi terhadap 9.769 baris pada test.csv. Hasil prediksi disusun mengikuti format sample_submission.csv, dengan kolom id dan income (berisi label string $\leq 50K$ atau $> 50K$), dan telah melalui validasi jumlah baris, urutan id, serta kelengkapan nilai sebelum disimpan sebagai submission.csv.

6.2 Kesimpulan

Berdasarkan hasil analisis dan eksperimen, dataset memiliki distribusi target income yang tidak seimbang, dengan kelas $\leq 50K$ lebih dominan dibandingkan $> 50K$. Hasil EDA juga menunjukkan adanya perbedaan pola antara kedua kategori income pada

beberapa fitur, seperti age, hours-per-week, dan capital-gain. Temuan tersebut menjadi dasar dalam memahami karakteristik data sebelum dilakukan pemodelan.

Pada tahap preprocessing, missing value ditangani sesuai jenis fitur, fitur numerik dilakukan standardisasi, dan fitur kategorikal diubah menggunakan One-Hot Encoding. Feature engineering melalui transformasi logaritmik pada capital-gain dan capital-loss juga diuji untuk menangani distribusi yang skewed, tetapi tidak meningkatkan performa model sehingga fitur original tetap digunakan.

Dari tiga model yang diuji, CatBoost memberikan performa terbaik dengan nilai F1-Macro sebesar 0,8103, lebih tinggi dibandingkan Random Forest sebesar 0,7894 dan Logistic Regression sebesar 0,7824. Oleh karena itu, CatBoost dengan fitur original dipilih sebagai model final. Model tersebut kemudian digunakan untuk mempelajari pola hubungan antara karakteristik individu dengan kategori income dari data training, lalu menghasilkan prediksi $\leq 50K$ atau $> 50K$ pada data testing.

Lembar Deklarasi Penggunaan AI

Proyek : Prediksi Kategori Pendapatan Individu
Studi Kasus: Census Income (KDD) Dataset

Nahdah Runa Musyaffa - 103012530054

Mengacu pada Pedoman Penggunaan Artificial Intelligence untuk Pembelajaran dan Pengajaran Universitas Telkom (Keputusan Wakil Rektor Bidang Akademik Nomor KWR1.030/AKD08/AKD-BPA/2025).

AI Tools

ChatGPT (GPT-5.6 Luna), Agustus 2026. Digunakan sebagai alat bantu dalam memahami konsep, memberikan alternatif pendekatan, membantu debugging kode, serta mendukung proses penyuntingan laporan. Seluruh tindakan awal dan lanjutan, keputusan metode, proses analisis, interpretasi hasil, pengembangan analisis, serta hasil akhir ditentukan dan dilakukan oleh penulis. AI digunakan hanya sebagai pendukung proses pengerjaan dan bukan sebagai penentu keputusan atau hasil akhir. .

Aspek	Penggunaan	Keterangan Penggunaan AI
Conceptualization	Ya	AI membantu brainstorming tujuan proyek dan daftar pertanyaan yang dapat digunakan dalam EDA.
Methodology	Ya	AI digunakan untuk memahami dan mendiskusikan alur pengerjaan secara garis besar sebelum eksekusi. Pada bagian ini juga digunakan untuk memahami setiap tahap yang dijalankan. Kemudian merekomendasikan jenis model yang digunakan.
Info Collection	-	AI tidak digunakan untuk mencari referensi atau merangkum bacaan eksternal.
Data Collection	Ya	AI memberikan daftar pertanyaan untuk rekomendasi EDA.
Execution	Ya	AI digunakan sebagai pendamping riset dalam proses learning by doing, terutama dalam mengimplementasikan konsep preprocessing yang telah dipahami ke dalam kode serta mempelajari implementasi CatBoost. AI juga membantu debugging, sementara eksperimen, analisis hasil, dan pengambilan keputusan dilakukan secara mandiri. Sebagian pemodelan dengan menerapkan konsep mandiri. AI membantu menyusun struktur technical report serta cara penulisan struktur berkas.
Data Curation	-	AI tidak menyusun tabel atau data hasil observasi.
Data Analysis	Ya	AI digunakan pada tahap visualisasi EDA dan data understanding. Serta pada tahap bonus membantu memahami jenis statistik yang sesuai.
Interpretation	Ya	AI membantu pada tahap kesimpulan.
Visualization	Ya	AI membuat bagan alur atau <i>workflow</i> yang diterapkan, membuat alur preprocessing, feature engineering, dan alur fiksasi yang telah diterapkan

		pada kode.
Writing - Editing	Ya	AI mengoreksi tata cara penulisan dan penggunaan atau pemilihan kata yang tepat dan efisien pada laporan dan berkas lainnya.
Writing - Translation	Ya	Digunakan pada pemahaman arti dari kolom-kolom pada data yang berbahasa inggris agar mempermudah analisis rekomendasi dan yang lainnya.